

Исследование точности алгоритма HyperLogLog

Отчет

В отчете исследуется алгоритм HyperLogLog (HLL), оценивающий F_0^t — число уникальных объектов в префиксе потока на момент времени t . Для сравнения вычисляются:

- точное значение F_0^t ;
- оценка HyperLogLog N_t .

Этап 1. Инфраструктура

Генератор потока. Реализован генератор потока строк длиной до 30 символов. Допустимые символы: прописные и строчные латинские буквы, цифры 0–9, тире. Для моделирования момента времени t поток разбивается на префиксы фиксированного шага (например, 5%, 10%, ...).

Хеш-функция. Реализована 32-битная хеш-функция $h : U \rightarrow [0, 2^{32})$ (равномерное распределение значений по диапазону). Используется фиксированный набор хешей, одинаковый для всех экспериментов.

Этап 2. Реализация HyperLogLog

Параметр B . Выбран размер индекса субпотока B и число регистров $m = 2^B$. В экспериментах использовано:

$$B = 12, \quad m = 2^{12} = 4096.$$

Обработка элемента. Для элемента x вычисляется $y = h(x)$ (32 бита). Первые B бит задают индекс регистра j , оставшиеся биты образуют w . Обновление регистра:

$$R[j] \leftarrow \max(R[j], \rho(w)),$$

где $\rho(w)$ — позиция первой единицы (число ведущих нулей +1) в w .

Оценка мощности. Базовая оценка:

$$E = \alpha_m \cdot m^2 \left(\sum_{j=0}^{m-1} 2^{-R[j]} \right)^{-1}.$$

Используются стандартные поправки:

- *small-range correction* (linear counting) при малых мощностях;
- *large-range correction* для больших значений.

Точное значение. Точное F_0^t вычисляется как размер множества уникальных элементов в префиксе потока.

Сбор статистик. Сгенерировано несколько независимых потоков. Для каждого момента времени t вычислены:

- оценка N_t и точное F_0^t ;
- выборочные $\mathbb{E}(N_t)$ и σ_{N_t} по всем потокам:

$$\mathbb{E}(N_t) = \frac{1}{S} \sum_{s=1}^S N_t^{(s)}, \quad \sigma_{N_t} = \sqrt{\frac{1}{S} \sum_{s=1}^S \left(N_t^{(s)}\right)^2 - \mathbb{E}(N_t)^2}.$$

Этап 3. Анализ результатов работы стандартного HyperLogLog

1) Точность и соответствие теоретическим отклонениям

Теоретическая относительная СКО (RSE) для HyperLogLog:

$$\text{RSE} \approx \frac{1.04}{\sqrt{2^B}}, \quad \text{а также грубая граница} \quad \frac{1.3}{\sqrt{2^B}}.$$

Для $B = 12$ имеем $\sqrt{2^{12}} = 64$, поэтому:

$$\frac{1.04}{64} \approx 1.63\%, \quad \frac{1.3}{64} \approx 2.03\%.$$

Практически относительный разброс оценивается как:

$$\text{rse}_t = \frac{\sigma_{N_t}}{\mathbb{E}(F_0^t)}.$$

По графикам N_t близок к F_0^t на всём диапазоне t , а область $\mathbb{E}(N_t) \pm \sigma_{N_t}$ остаётся узкой. Это соответствует теоретическому масштабу отклонений для выбранного B .

2) Стабильность оценки (дисперсия)

Абсолютная величина σ_{N_t} растёт при увеличении F_0^t , так как увеличивается масштаб значений. При фиксированном числе регистров $m = 2^B$ относительный разброс σ_{N_t}/F_0^t должен оставаться примерно постоянным. На графике статистик зона неопределённости не демонстрирует резкого роста относительно уровня оценки, что соответствует ожидаемой стабильности HLL.

3) Эффективность констант и их влияние

- **Параметр B .** Выбор между «память–точность»: при росте B ошибка уменьшается как $1/\sqrt{2^B}$, но увеличивается число регистров m .
- **Константа α_m .** Влияет на смещение оценки; корректные значения уменьшают систематическую ошибку.
- **Small-range correction (linear counting).** Существенно улучшает качество на ранних стадиях потока (при большом числе нулевых регистров).
- **Large-range correction.** Для 32-битного хеша проявляется только при очень больших мощностях; для рассматриваемых размеров потока влияние незначительно.
- **Хеш-функция.** Равномерность распределения по субпотокам напрямую влияет на bias и дисперсию; при хорошем хеше практические результаты ближе к теории.

Вывод

При выбранном $B = 12$ алгоритм HyperLogLog демонстрирует поведение, согласующееся с теоретическими оценками относительной ошибки порядка 1.63% (и грубой границы 2.03%). Оценка стабильна по времени, а используемые стандартные константы и поправки корректно уменьшают смещение и улучшают качество на малых мощностях.